

World Model и VLM-based scorer для управления агентом в MiniGrid

1 Краткое описание

В работе реализован небольшой демо-проект, объединяющий learned world model в стиле RSSM и VLM-based scorer для управления агентом в среде MiniGrid. Агент получает RGB-наблюдения, строит латентное состояние при помощи RSSM, затем планирует действия через MPC с random shooting. Для каждого набора кандидатных действий world model генерирует imagined rollout, декодирует будущие латентные состояния в RGB-кадры, после чего VLM scorer оценивает степень достижения текстовой цели по этим будущим кадрам.

Ключевое условие задания выполнено: VLM применяется не к текущему наблюдению, а к будущим кадрам, предсказанным world model. Основной результат: добавление goal-crop VLM scorer к planning улучшило качество относительно reward-only world model planner.

2 Среда и постановка задачи

В качестве основной среды использовалась MiniGrid-Empty-6x6-v0. Цель агента — дойти до зеленой клетки goal. Наблюдения представлялись как RGB-кадры размера 64×64 . Для рендера использовался режим `highlight=False`, чтобы убрать подсветку поля зрения агента и сделать визуальные наблюдения стабильнее.

Action space был ограничен действиями `left`, `right`, `forward`. Такого набора достаточно для пустой среды, поскольку в ней нет ключей, дверей и других объектов. Текстовая цель для VLM была сформулирована как достижение состояния, где красный агент находится внутри или поверх зеленой клетки.

Для обучения world model был собран датасет из 700 train-эпизодов: 450 эпизодов со случайной политикой и 250 эпизодов с простой oracle-политикой. Валидационная выборка состояла из 80 эпизодов: 40 случайных и 40 oracle. В тренировочном датасете оказалось 280 успешных эпизодов из 700. Число transition-ов с ненулевой наградой также равно 280, так как MiniGrid выдает sparse reward только один раз при достижении goal, после чего эпизод завершается.

3 Используемый подход

3.1 RSSM world model

World model построена в стиле RSSM, используемом в PlaNet и Dreamer. Модель содержит:

- сверточный энкодер, переводящий RGB-кадр в embedding;
- детерминированное состояние на основе GRU;
- стохастическое латентное состояние;
- априорное распределение $p(z_t | h_t)$;
- апостериорное распределение $q(z_t | h_t, o_t)$;
- декодер, восстанавливающий RGB-кадр из латентного состояния;

- reward head;
- continue head;
- auxiliary direction head для предсказания направления агента.

Для диагностики использовались две реконструкции:

- **post**: реконструкция из апостериорного латентного состояния, который видел настоящий следующий кадр;
- **prior**: реконструкция из априорного скрытого состояния, который не видел настоящий следующий кадр и поэтому ближе к imagined rollout при planning.

Для planning важнее именно prior, поскольку imagined rollouts строятся без доступа к будущим реальным наблюдениям.

3.2 Функция потерь

Итоговая функция потерь включала несколько компонентов:

$$L = L_{\text{recon}} + \alpha L_{\text{prior_recon}} + \beta L_{\text{reward}} + \gamma L_{\text{continue}} + \delta L_{\text{direction}} + \lambda L_{\text{KL}}. \quad (1)$$

Для reconstruction loss использовалась weighted BCE: пиксели красного агента и зеленой цели имели повышенный вес. Это было сделано потому, что именно агент и goal важны для VLM scorer и планирования, но занимают мало пикселей на изображении.

Auxiliary direction loss был добавлен для того, чтобы RSSM лучше кодировал ориентацию агента. Это важно для MiniGrid, где действие **forward** зависит от текущего направления.

3.3 VLM scorer

В качестве VLM использовался CLIP через Hugging Face Transformers. Сначала был протестирован full-frame scorer, который оценивал весь кадр. Этот вариант оказался шумным: CLIP реагировал на глобальную структуру MiniGrid, стены и артефакты рендера, а не только на отношение красного агента и зеленой цели.

Поэтому финальный вариант использует goal-crop preprocessing: перед подачей в CLIP из кадра вырезается область вокруг зеленой клетки. Это делает scorer более локальным и заставляет его оценивать вопрос: находится ли красный агент в области goal.

Скоринг вычислялся как разность между максимальной похожестью изображения на positive prompts и максимальной похожестью на negative prompts:

$$\text{score}(I) = \max_j \text{sim}(I, p_j^+) - \max_k \text{sim}(I, p_k^-). \quad (2)$$

Примеры positive prompts:

- “a red triangle inside a bright green square”;
- “a red arrow overlapping a green square”;
- “the green square contains the red agent”.

Примеры negative prompts:

- “an empty bright green square”;
- “a green square without a red triangle inside”;
- “a red triangle next to the green square but outside it”.

3.4 Planning

Planning выполнялся через MPC с random shooting. На каждом шаге агент:

1. кодирует текущий реальный кадр в RSSM state;
2. случайно сэмплирует набор кандидатных последовательностей действий длины H ;
3. прогоняет эти последовательности через RSSM prior dynamics;
4. декодирует будущие latent states в imagined frames;
5. оценивает rollouts через reward objective и, при необходимости, VLM scorer;
6. выполняет только первое действие лучшей последовательности.

Для reward-only planner objective задавался как discounted predicted reward с дополнительными штрафами за долгий rollout и лишние повороты:

$$J_{\text{reward}} = \sum_t \gamma^t \hat{r}_t - c_{\text{time}} C_{\text{time}} - c_{\text{turn}} C_{\text{turn}}. \quad (3)$$

Для VLM planner использовался reranking. Сначала выбирались top-k rollouts по reward objective. Затем VLM scorer применялся к будущим кадрам этих rollouts. Итоговый objective:

$$J = w_r \cdot \text{norm}(J_{\text{reward}}) + w_v \cdot \text{norm}(J_{\text{VLM}}). \quad (4)$$

4 Экспериментальный раздел

Сравнивались три основных метода:

- **Random**: случайный выбор действий из `left`, `right`, `forward`;
- **World Model Reward**: MPC planning в RSSM без VLM scorer;
- **World Model + VLM**: MPC planning с goal-crop VLM reranking.

Оценка проводилась на 20 фиксированных seed-ах: 2000, ..., 2019. Метрики:

- success rate;
- mean return;
- mean episode length.

Mean return важен наряду с success rate, поскольку reward в MiniGrid зависит от скорости достижения цели: чем быстрее агент доходит до goal, тем выше return.

5 Результаты

5.1 Основное сравнение

Метод	Episodes	Success rate	Mean return	Mean length
Random	20	0.40	0.1729	54.55
World Model Reward	20	0.85	0.5533	30.70
World Model + VLM Goal Crop	20	0.90	0.5927	28.25

Таблица 1: Основное сравнение методов на MiniGrid-Empty-6x6-v0.

World model planning существенно превосходит random baseline. Добавление goal-crop VLM scorer дает дополнительный прирост: success rate увеличивается с 0.85 до 0.90, mean return увеличивается с 0.5533 до 0.5927, а mean length уменьшается с 30.70 до 28.25.




Рис. 1: Основные метрики: success rate, mean return и mean length.

5.2 Ablation VLM scorer

Метод	Success rate	Mean return	Mean length
World Model Reward	0.85	0.5533	30.70
World Model + VLM Full Frame	0.80	0.4541	37.40
World Model + VLM Goal Crop	0.90	0.5927	28.25

Таблица 2: Ablation для VLM scorer.

Full-frame VLM scorer ухудшает результат относительно reward-only planner. Goal-crop VLM scorer, наоборот, улучшает все метрики. Это показывает, что для синтетических MiniGrid-кадров важно не просто использовать CLIP, а правильно локализовать визуальный контекст цели.




Рис. 2: Ablation: reward-only, full-frame VLM и goal-crop VLM.

6 Визуализации

6.1 Качество world model




Рис. 3: Сравнение real, posterior reconstruction и prior reconstruction.

На визуализации видно, что prior и posterior reconstruction близки к real frames. Это важно, потому что planning использует именно prior dynamics. Направление агента также стало лучше различимо после добавления auxiliary direction loss. Остается небольшой ghosting красного агента, но геометрия среды, green goal и положение агента в целом восстанавливаются корректно.

6.2 VLM sanity check




Рис. 4: Goal-crop VLM scorer на успешной траектории.

Goal-crop scorer дает низкие значения для состояний, где агент далеко от goal, и положительные значения, когда агент находится рядом с goal или на goal. В одном из sanity check значения были примерно: -2.23 для дальних состояний, 1.17 рядом с goal и 1.90 на goal. Это показывает, что crop вокруг зеленой клетки существенно улучшил grounding VLM scorer.




Рис. 5: Full-frame VLM scorer на той же траектории.

Full-frame scorer оказался менее надежным, что согласуется с ablation: он ухудшает planning относительно reward-only baseline.

6.3 Imagined rollout




Рис. 6: Пример imagined rollout с VLM scores для будущих кадров.

Эта визуализация демонстрирует ключевую часть метода: VLM scorer применяется к future frames, которые были сгенерированы RSSM world model при rollout-е кандидатной последовательности действий.

7 Обсуждение

7.1 Основные failure modes

Во время экспериментов были замечены следующие failure modes:

- **Full-frame VLM плохо привязан к цели.** CLIP на полном MiniGrid-кадре может реагировать на стены, глобальную структуру и артефакты рендера, а не на отношение агента и goal.
- **VLM путает near goal и on goal.** До использования goal crop scorer часто давал высокий score состояниям, где агент рядом с зеленой клеткой, но еще не на ней.
- **Ghosting в RSSM reconstructions.** World model иногда рисует слабый след агента в нескольких позициях. Это может создавать ложноположительные VLM scores.
- **Random shooting не гарантирует оптимальность.** Даже при хорошей world model конечное число случайных candidate sequences не всегда содержит лучший путь.
- **Success rate на 20 эпизодах грубый.** Один failed episode меняет success rate на 0.05, поэтому mean return и mean length дают более детальную картину.
- **Ограниченный горизонт planning.** Planner оценивает rollouts длины $H = 10$. Если goal требует более длинной последовательности действий, агент может не увидеть успешное состояние внутри текущего горизонта и выбрать локально неоптимальное действие.

7.2 Что сработало лучше всего

Наиболее полезными изменениями оказались:

- отключение MiniGrid highlight в рендере;
- weighted reconstruction loss для агента и goal;
- auxiliary direction loss;
- prior reconstruction loss;
- goal-crop preprocessing для VLM scorer;
- VLM reranking поверх top-k reward rollouts вместо полного замещения reward objective.

8 Future Work

При большем времени я бы попробовал следующие направления:

- увеличить planning horizon или использовать CEM для более надежного поиска длинных action sequences;
- увеличить число evaluation seeds до 50 или 100;
- протестировать harder setting MiniGrid-Empty-8x8-v0;
- перейти к DoorKey environment как более сложной задаче с объектами и состоянием двери;
- обучить небольшой специализированный visual scorer на MiniGrid frames;
- использовать latent-space scorer вместо CLIP по decoded images;
- добавить actor-critic поверх RSSM в стиле Dreamer.

9 Заключение

В проекте реализована связка RSSM world model, imagined rollouts, VLM-based scorer и MPC planning. World model planning значительно превзошел random baseline, а goal-crop VLM scorer дополнительно улучшил результат относительно reward-only world model planner. Ablation показала, что full-frame VLM scorer может ухудшать качество, тогда как локализация вокруг goal делает VLM signal полезным. Финальный метод достиг success rate 0.90, mean return 0.5927 и mean length 28.25 на 20 эпизодах.